



MAYO 2026 |
LAE

PREDICCIÓN DEL CSAT SCORE EN UN CALL CENTER



Por Sofia Anaya y
Diego Dueñas



OBJETIVO GENERAL

Predecir el **CSAT** Score usando características de la interacción

CUSTOMER SATISFACTION SCORE



ID	Customer Name	Sentiment	CSAT Score	Call Timestamp	Reason	City	State	Channel	Response Time	Call Duration (Minutes)	Call Center
PIS-39858047	Frances Gullefant	Neutral	8	01/01/24	Billing Question	Charleston	West Virginia	Chatbot	Within SLA	14	Chicago/IL
ROH-40287216	Harcourt Zoanetti	Negative	5	01/01/24	Billing Question	Honolulu	Hawaii	Call-Center	Within SLA	32	Los Angeles/CA
NKC-39578431	Washington Oxtoby	Negative	3	02/01/24	Billing Question	Dallas	Texas	Chatbot	Within SLA	6	Denver/CO
APY-17008648	Rafe Duffitt	Very Negative	4	02/01/24	Billing Question	Fort Myers	Florida	Email	Below SLA	26	Los Angeles/CA
MHK-38443501	Tris Bent	Positive	8	02/01/24	Billing Question	Tuscaloosa	Alabama	Web	Within SLA	26	Los Angeles/CA
QKL-49133006	Kassie Elman	Very Negative	4	03/01/24	Billing Question	Charleston	South Carolina	Web	Within SLA	6	Baltimore/MD
ZPZ-31710059	Elbertina Hewins	Very Positive	10	03/01/24	Payments	Pensacola	Florida	Call-Center	Within SLA	9	Los Angeles/CA
IJF-13083880	Garland Chuney	Negative	3	04/01/24	Billing Question	Little Rock	Arkansas	Call-Center	Within SLA	15	Baltimore/MD
ZKW-68562847	Caroljean Bishop	Negative	3	04/01/24	Billing Question	Nashville	Tennessee	Web	Within SLA	12	Los Angeles/CA
NIL-47926257	Delmor McKleod	Negative	6	05/01/24	Billing Question	El Paso	Texas	Web	Within SLA	42	Los Angeles/CA
BPQ-80812775	Julee O'Gavin	Negative	3	05/01/24	Billing Question	Santa Ana	California	Chatbot	Above SLA	44	Baltimore/MD
ZOK-34480332	Jaye Gribbon	Neutral	7	06/01/24	Billing Question	Huntington	West Virginia	Chatbot	Within SLA	29	Baltimore/MD
ZMB-79323804	Brodie Dobrowski	Negative	5	06/01/24	Billing Question	Pittsburgh	Pennsylvania	Chatbot	Within SLA	35	Baltimore/MD
YYO-56445305	Sibylla Kemet	Very Negative	2	07/01/24	Billing Question	Tucson	Arizona	Web	Within SLA	30	Los Angeles/CA
JYD-67455825	Quintilla Hourston	Negative	6	07/01/24	Payments	Des Moines	Iowa	Call-Center	Within SLA	29	Los Angeles/CA
KNO-93249512	Maggi Simpson	Positive	9	08/01/24	Payments	San Francisco	California	Call-Center	Within SLA	9	Baltimore/MD
YEG-62862025	Frank Anderson	Very Positive	9	08/01/24	Billing Question	Lansing	Michigan	Chatbot	Within SLA	9	Los Angeles/CA



LAE

OBJETIVOS ESPECÍFICOS

1. Limpiar y preparar los datos
2. Transformar variables categóricas a números
3. Entrenar 3 modelos (Árbol, Random Forest, XGBoost)
4. Optimizar sus hiperparámetros
5. Comparar resultados
6. Identificar qué variables más influyen






DATOS

70 x 12


Columna	Tipo	¿Para qué sirve?
Sentiment	Texto	Emoción detectada (Very Negative a Very Positive)
CSAT Score	Número (1-10)	Lo que queremos predecir
Call Duration	Número	Minutos que duró la llamada
Channel	Texto	Canal: Chatbot, Email, Web, Call-Center
Response Time	Texto	Cumplió el SLA (Within, Below, Above)
Reason	Texto	Motivo: Billing, Payments, Service Outage
Call Center	Texto	Oficina que atendió (Chicago, LA, Denver, Baltimore)

ACLARAR: ID, CUSTOMER NAME, TIMESTAMP, CITY, STATE SE **DESCARTARON** (NO APORTAN PODER PREDICTIVO)


Distribucion del CSAT Score




CSAT promedio por Sentimiento




CSAT promedio por Canal




CSAT por Response Time



CSAT vs Duracion



CSAT por Razon






LAE

PREPARACIÓN DE DATOS

Variable	Problema	Solución
Sentiment	Tiene orden (Very Negative < Negative < Neutral...)	Asignamos números 1,2,3,4,5
Response Time	Tiene orden (Below SLA < Within SLA < Above SLA)	1,2,3
Channel	NO tiene orden (Chatbot no es mayor/menor que Email)	One-Hot Encoding: crear columnas separadas
Reason	NO tiene orden	One-Hot Encoding
Call Center	NO tiene orden	One-Hot Encoding
Reason	Texto	Motivo: Billing, Payments, Service Outage
Call Center	Texto	Oficina que atendió (Chicago, LA, Denver, Baltimore)



Explicación de One-Hot Encoding

Channel original	Channel_Chatbot	Channel_Email	Channel_Web	Channel_CallCenter
Chatbot	1	0	0	0
Email	0	1	0	0
Web	0	0	1	0
Call-Center	0	0	0	1



Escalación de variables numéricas

"Creamos DOS versiones del problema: una de regresión y una de clasificación."

Call Duration

6 a 32 (min)

(valor - media)

(D.E)

Las dos variables objetivos


Enfoque	Variable	Pregunta que responde
Regresión	CSAT Score (1-10)	¿Cuánto va a calificar?
Clasificación	Alto (≥ 7) vs Bajo (< 7)	¿Va a estar satisfecho o no?

POR QUÉ: LA CLASIFICACIÓN ES MÁS ÚTIL OPERATIVAMENTE (SOLO ME IMPORTA SI ESTÁ CONTENTO O ENOJADO)


Modelo 1: Árbol de Decisión

- Ventaja: es interpretable. Podemos visualizar y entender exactamente qué decisión tomó.
- Desventaja: tiende a sobreajustar

Arbol de Decision optimo — Regresion (depth=2, mostrando hasta nivel 2)



Modelo 1: Árbol de Decisión






LOS TRES MODELOS




Modelo 2: Random Forest

- Se contruyeron varios árboles (en nuestro caso 500). Cada árbol ve una muestra diferente de los datos y usa un subconjunto aleatorio de variables. Al final promediamos las predicciones de todos los árboles.



Modelo 3: XGBoost

- Aquí los árboles se construyen uno TRAS otro. Cada árbol nuevo se enfoca en corregir los errores del anterior. Si un cliente fue mal predicho, el siguiente árbol le da más importancia.



OPTIMIZACIÓN CON BÚSQUEDA BAYESIANA



Parámetro	Qué controla	Rango probado
n_estimators	Número de árboles	50 a 200
max_depth	Profundidad máxima	3 a 20
min_samples_split	Mínimo datos para dividir	2 a 10
min_samples_leaf	Mínimo datos en una hoja	1 a 5
max_features	% de variables a considerar	30% a 100%

RESULTADO: EL MEJOR RANDOM FOREST TUVO MAX_DEPTH=20, N_ESTIMATORS=50, MIN_SAMPLES_SPLIT=10



VALIDACIÓN CRUZADA

- Dividimos los datos en 5 partes iguales
- Entrenamos 5 veces:
- 4 partes para entrenar, 1 parte para validar
- Rotamos cuál parte se usa para validar
- Calculamos el promedio y la desviación estándar



LAE MÉTRICAS DE EVALUACIÓN

PARA REGRESIÓN (CSAT CONTINUO 1-10)

Métrica	Qué mide	Fórmula simple	Rango	Mejor valor
R ²	% de variabilidad explicada	1 - (error del modelo / error de la media)	0 a 1	Más alto
RMSE	Error típico	raíz(promedio de errores al cuadrado)	0 a ∞	Más bajo
MAE	Error promedio	promedio(real - predicho)	0 a ∞	Más bajo

¿POR QUÉ ELEGIMOS R² PARA OPTIMIZAR?


ES FÁCIL DE EXPLICAR: UN R² DE 0.73 SIGNIFICA QUE EL MODELO EXPLICA EL 73% DE LA VARIABILIDAD DEL CSAT.

EJECUTIVOS ENTIENDEN ESO. EL RMSE SUENA A 'RAÍZ DE...' Y ES MÁS DIFÍCIL DE COMUNICAR.



RMSE: RAÍZ DEL ERROR CUADRÁTICO MEDIO

MAE: ERROR ABSOLUTO MEDIO



"SI TUS DATOS TIENEN MONSTRUOS (OUTLIERS), USA MAE. SI TUS ERRORES GRANDES SON MONSTRUOS, USA RMSE."


LAE MÉTRICAS DE EVALUACIÓN

PARA CLASIFICACIÓN (ALTO VS BAJO)

Métrica	Qué mide	Rango	Mejor valor
AUC-ROC	Capacidad de distinguir entre clases	0 a 1	Más alto

¿POR QUÉ AUC-ROC?





LAS CLASES ESTÁN DESBALANCEADAS: 47 CLIENTES DIERON CSAT BAJO Y SOLO 23 DIERON ALTO. SI UN MODELO SIEMPRE PREDICE 'BAJO', TENDRÍA 67% DE PRECISIÓN PERO NO SERÍA ÚTIL.



RESULTADOS - TABLA

Modelo	R ² (Regresión)	AUC (Clasificación)
Árbol Decisión	0.71 ± 0.11	0.96 ± 0.06
Random Forest	0.73 ± 0.08	0.96 ± 0.05
XGBoost	0.73 ± 0.05	0.96 ± 0.06

LOS TRES MODELOS RINDEN MUY SIMILAR. RANDOM FOREST Y XGBOOST TIENEN MENOR DESVIACIÓN ESTÁNDAR, LO QUE SIGNIFICA QUE SON MÁS ESTABLES.






LAE

IMPORTANCIA DE VARIABLES

Variable	Importancia promedio
Sentiment_enc	72.50%
Call_Duration_Min	6.90%
Response_Time_enc	3.70%
Reason_Billing	2.70%
Channel_Web	1.80%

Comparacion de importancia de variables — los 6 modelos





**MUCHAS
GRACIAS**

